한양대학교 컴퓨터소프트웨어학부

PERTINENCE 기반
입력 적응형 CNN 모델 라우팅 시스템의
추론 서빙 구조 평가



정환 · 오우택

졸업프로젝트 결과 발표

입력별 모델 선택의 필요성

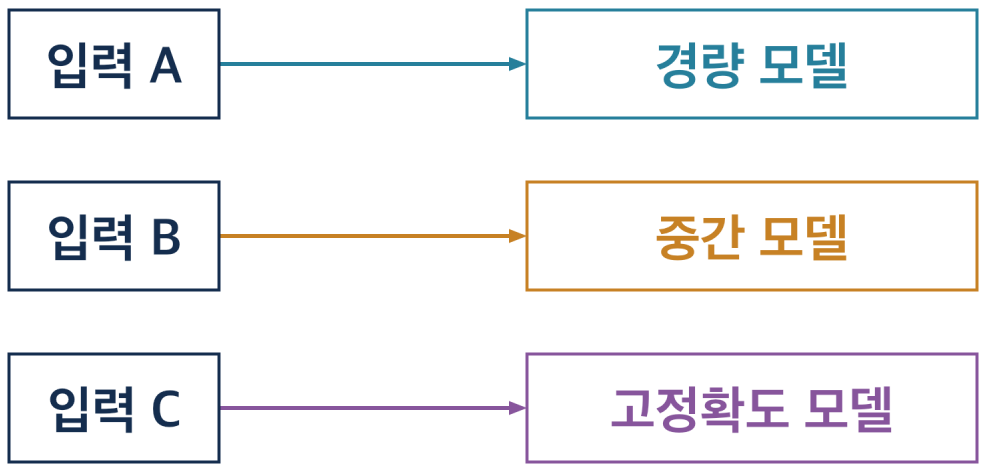
입력마다 필요한 계산량이 다르면 실행할 모델도 달라질 수 있다

고정 모델 실행



작은 모델은 정확도 제약
큰 모델은 높은 계산 비용

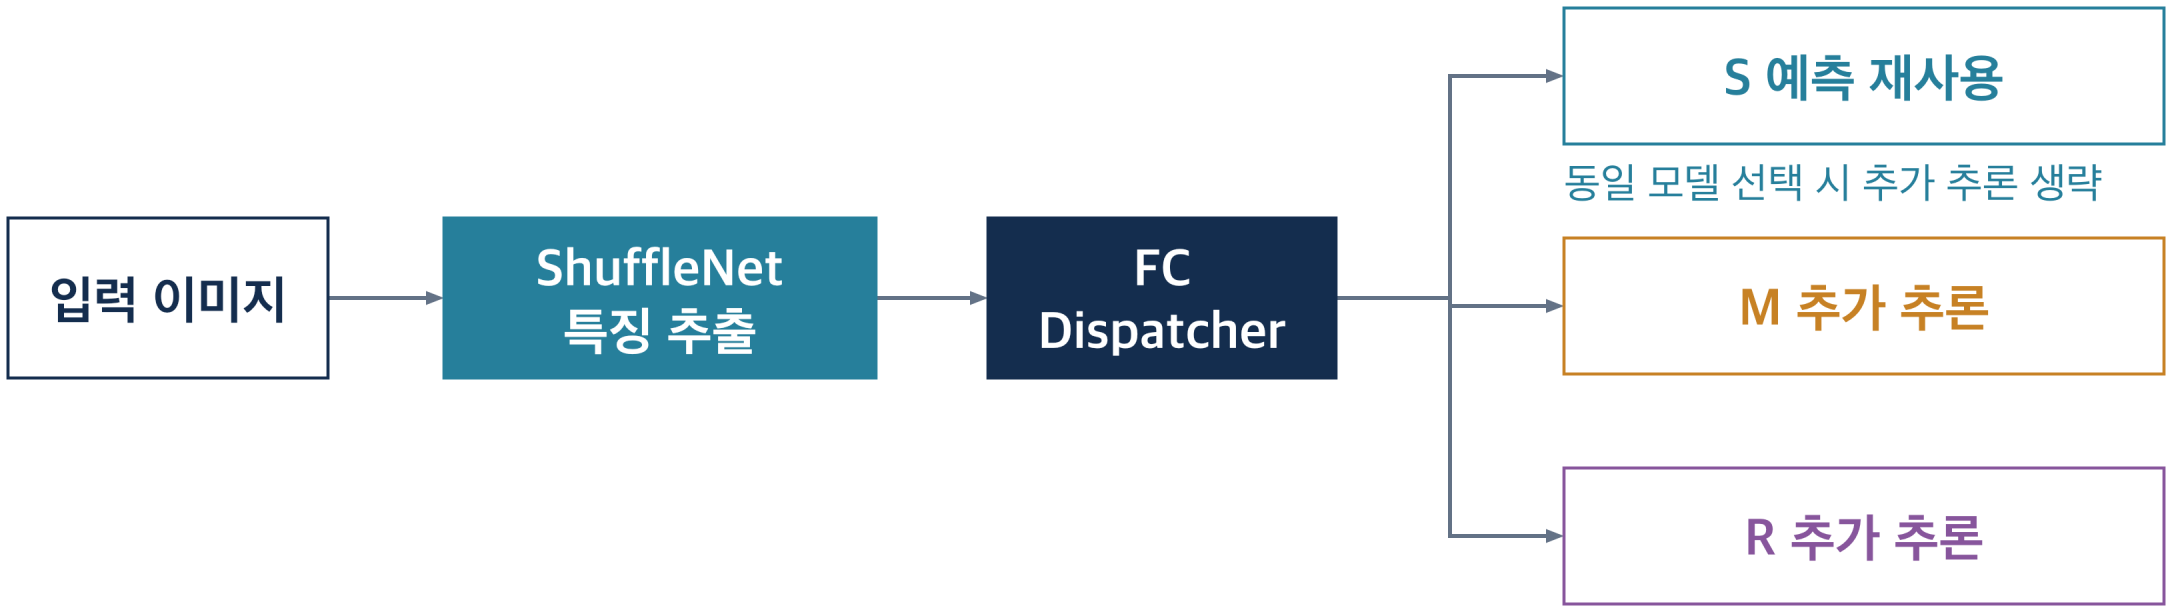
입력별 모델 선택



필요한 입력에 계산을 배분
평균 연산량 절감 가능성

PERTINENCE의 입력 기반 모델 선택

고정된 CNN 특징을 이용해 작은 FC dispatcher가 expert를 선택한다



Expert 가중치는 고정

학습 대상은 FC dispatcher

출력 = 이미지 클래스가 아닌 모델 번호

S: ShuffleNetV2 x0.5 M: MobileNetV2 x0.5 R: ResNet56

Dispatcher 학습과 정확도·연산량 절충

서로 다른 학습 설정으로 여러 운용점을 확보한다

01 **선택 라벨 생성**

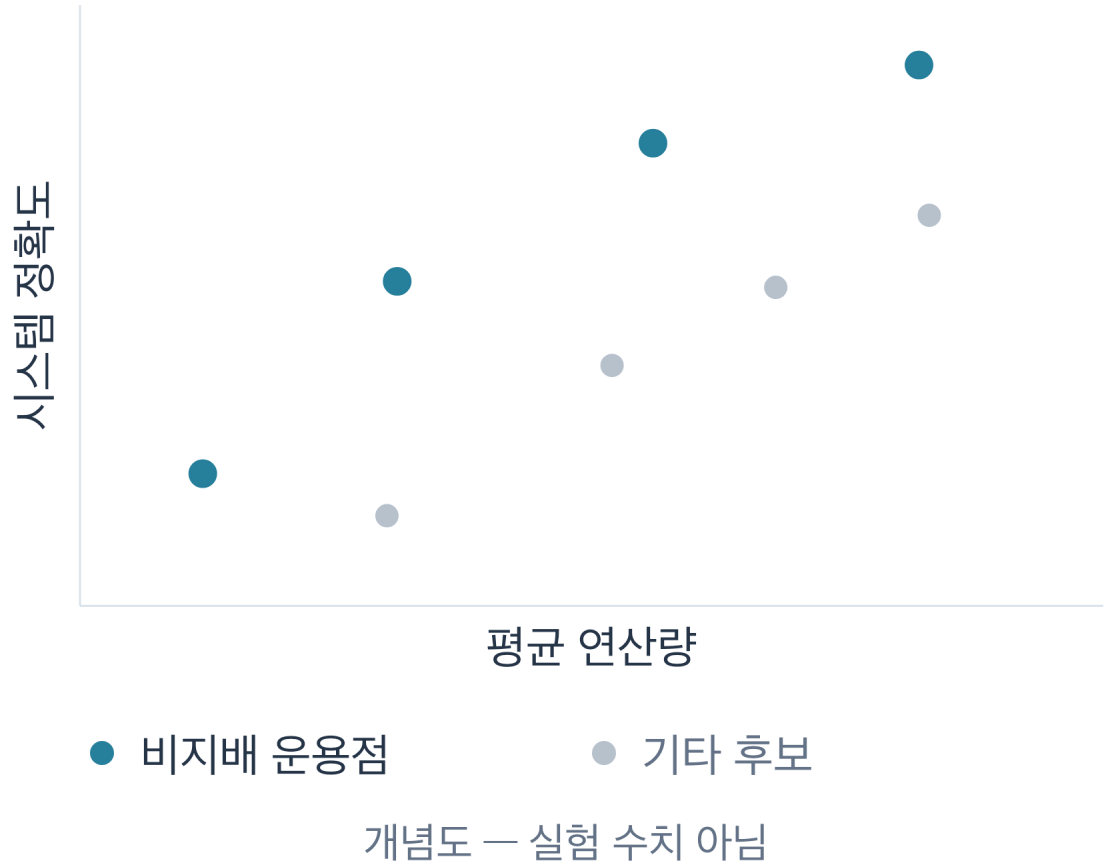
정답을 맞힌 후보 중
비용이 작은 모델 선택

02 **Dispatcher 학습**

가중치와 penalty 설정별
선택기 학습

03 **NSGA-II 탐색**

시스템 정확도와
평균 연산량 평가



개념도 — 실험 수치 아님

한 운용점은 하나의 학습된 dispatcher에 대응

연산량과 실제 서빙 비용

알고리즘의 계산량을 실제 서비스 성능과 함께 평가한다

전체 연산량

특징 추출 + Dispatcher + 선택 Expert의 추가 계산

알고리즘 평가

- 시스템 정확도
- 평균 연산량
- 모델 선택 비율

서비스 실행 비용

- 요청 처리와 데이터 변환
- 모델 호출과 통신
- 실행 장치와 자원 관리

프로젝트 목표와 평가 범위

PERTINENCE 구현부터 실제 서비스의 실행 효율 평가까지

01

PERTINENCE 구현

고정 CNN과 dispatcher
학습·탐색·평가

02

서빙 환경 구축

Kubernetes 기반 배포
입력별 모델 선택 실행

03

성능 평가·분석

정확도와 평균 연산량
지연시간·처리량·자원 사용량

평균 연산량의 차이가 실제 서빙 성능에 어떻게 반영되는지 확인

개발환경

GKE 위에서 학습을 자동화하고, CPU 기반 온라인 추론 성능을 검증했습니다.

Google Kubernetes Engine

학습부터 서빙까지

Kubeflow Pipelines

데이터 처리 · Dispatcher 학습 · 평가

↓

KServe

모델 배포 · 온라인 추론 실험

GPU 없이 CPU 사용 · 역할별 노드 풀 분리

자원 경쟁을 줄인 실험 환경

노드 풀	머신	역할
시스템	e2-standard-4	KFP 운영
학습	n2-standard-8	학습·평가
추론	n2-standard-8	모델 서빙
부하 생성	n2-standard-4	요청·측정

동일한 추론·부하 생성 노드를 사용하고 클러스터 내부에서 요청 전송

동적 모델 선택 및 학습 자동화

CIFAR-10 · Expert는 고정하고 Dispatcher를 학습 · NSGA-II로 정확도-연산량 절충 탐색



Expert: ShuffleNetV2 x0.5 / MobileNetV2 x0.5 / ResNet56



계산 컴포넌트 · 실행 순서	역할
01 validate-run	입력 검증 및 데이터 분할
02 build-routing-dataset	특징·예측·Routing 정답 캐시 생성
03 train-dispatcher	Dispatcher 학습 및 Pareto 후보 탐색
04 evaluate-final	최종 데이터에서 후보 성능 평가
05 register-dispatchers	모델 정보 및 평가 결과 등록

해시 검증 · 고정 seed · Train / Search / Final 분리로 재현성 확보

연산량은 줄었지만 응답시간은 증가

Warm-up 200건 → 평가 2,000건 · 5 RPS · 동시 요청 1 · 재시도 없음

요청 처리 구조

Direct

이미지 → ResNet56

Distributed

Router → 원격 특징 추출
→ Dispatcher → 원격 Expert

Direct: 내부 RPC 0회
Distributed: 내부 RPC 2회

지표	Direct	Distributed
정확도	94.60%	94.65%
MFLOPs	251.50	210.73
평균 지연	10.379ms	25.845ms
p95	12.646ms	30.379ms

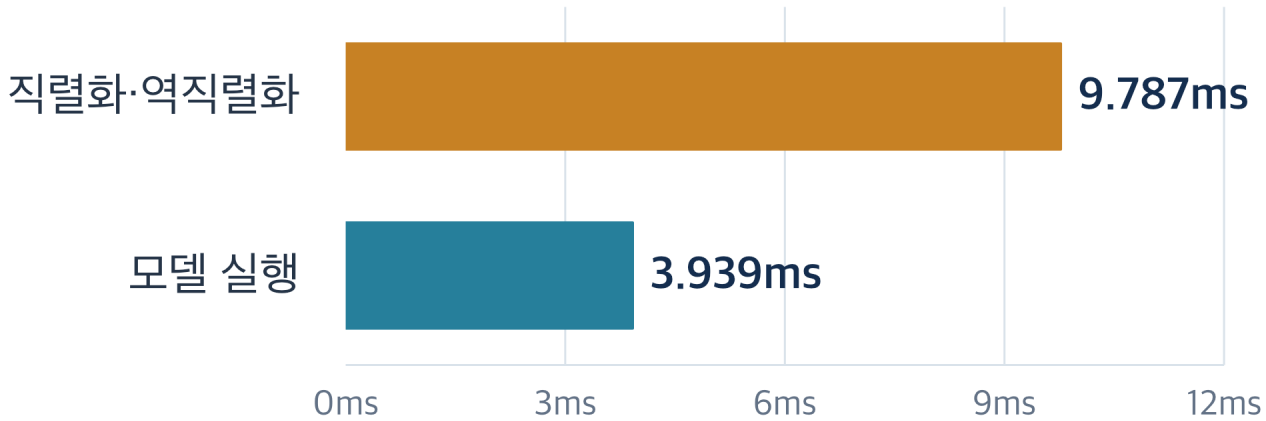
연산량 16.2% 감소에도 지연 증가 · 정확도 차이 0.05%p는 정답 1건

Predictor 자원: Direct 1 Pod·1 CPU·1 GiB / Distributed 4 Pod·총 4 CPU·4 GiB

모델 계산보다 큰 데이터 변환 비용

구간별 계측을 추가한 별도 실행으로 분산 추론의 병목을 확인했습니다.

요청당 CPU 시간



2.5배 모델 실행 대비 데이터 변환 CPU 시간

요청마다 반복되는 작업

이미지·특징을 JSON 숫자 문자열로 변환하고 다시 해석

내부 HTTP 호출 2회
새 연결 생성 2회

내부 전송 본문 합계 약 141KB

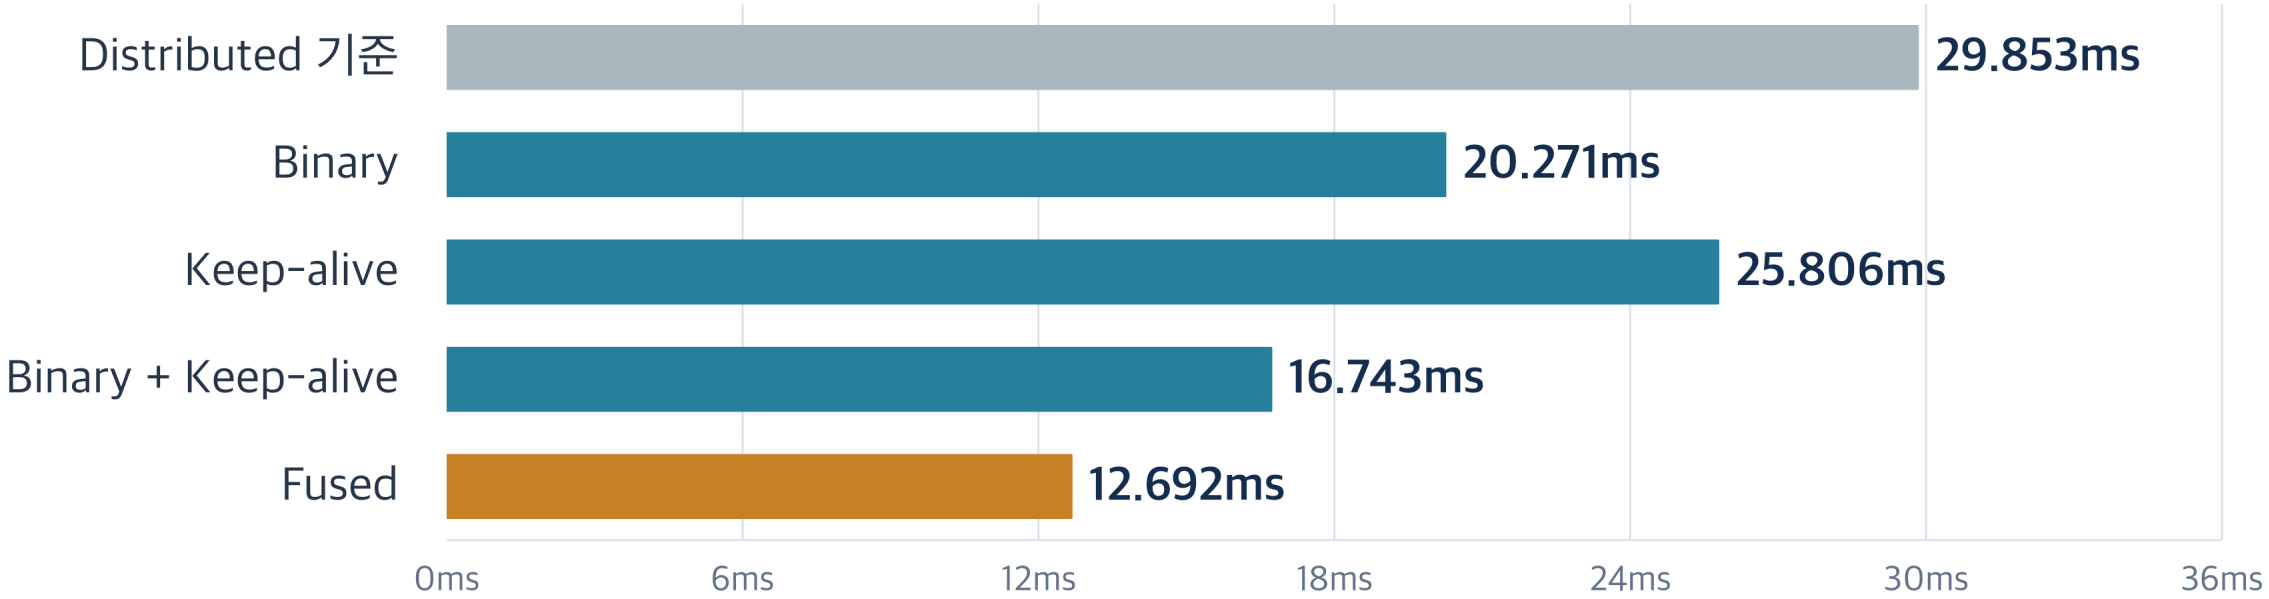
이 실행의 평균 응답시간: 29.853ms

모델 연산뿐 아니라 데이터 변환과 연결 처리도 최적화 대상

초기 비교와 별도 실행. CPU 시간과 경과 시간은 서로 다른 지표로, 합산할 수 없음.

통신 비용을 줄일수록 지연 감소

Binary로 변환 비용 감소 · Keep-alive로 연결 재사용 · Fused로 내부 RPC 제거



Binary + Keep-alive

기준 대비 평균 지연 43.9% 감소

Fused · 전체 모델 통합

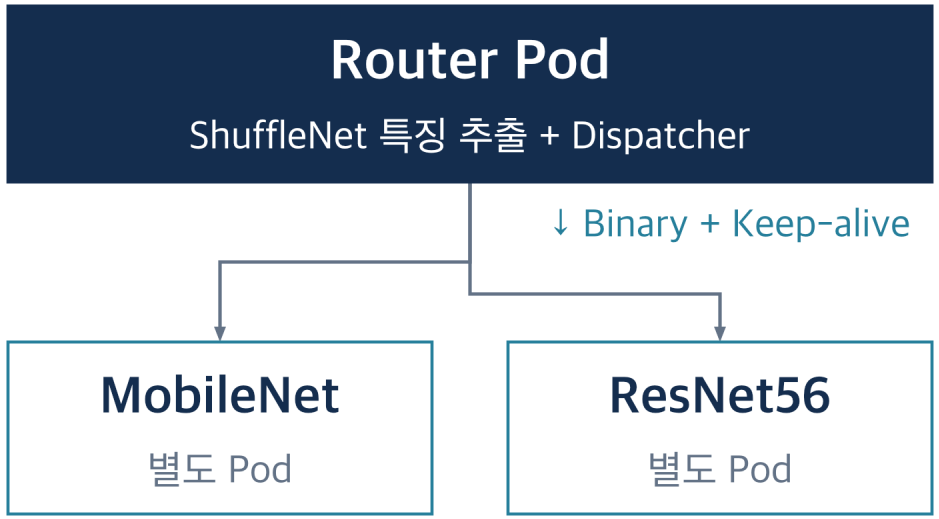
기준 대비 평균 지연 57.5% 감소

평균 지연시간 비교 · Predictor 총 4 CPU·4 GiB · 외부 JSON API 및 FP32 정밀도 유지

Hybrid: 통신은 줄이고, Expert는 독립 확장

Fused는 특정 Expert만 확장할 수 없어, 전체 Pod를 함께 복제해야 합니다.

공통 경로를 Router에 통합



선택된 Expert만 원격 호출 · 요청당 RPC 1회

항목	분산 최적화[1]	Hybrid	Fused
Pod	4	3	1
내부 RPC	2회	1회	0회
평균 지연	16.743ms	14.662ms	12.692ms
Expert별 독립 확장	가능	가능	전체 Pod

[1] Distributed + Binary + Keep-alive

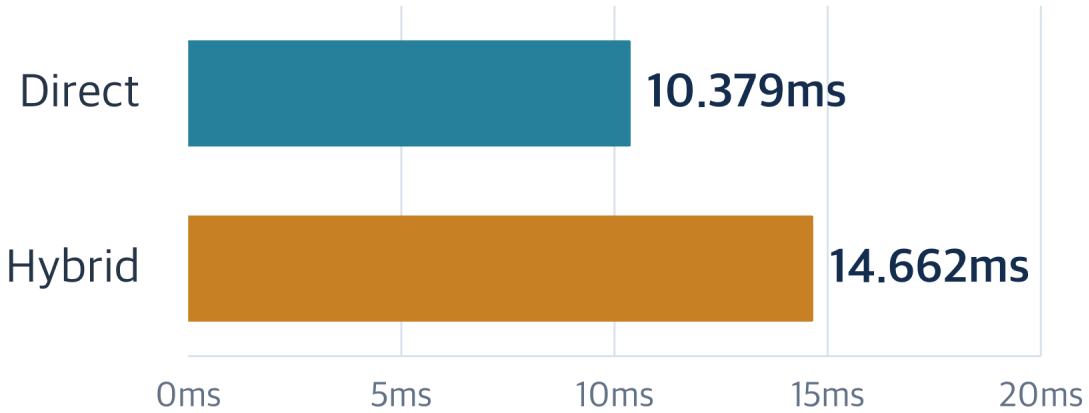
개선된 Distributed 대비 평균 지연 12.4% 감소 · Expert 독립 확장 유지

독립 확장이 가능한 구조이며, 부하 증가 시 처리량·자동 확장 효과는 추가 검증 필요

Hybrid도 Direct보다 빠르지 않았습니다

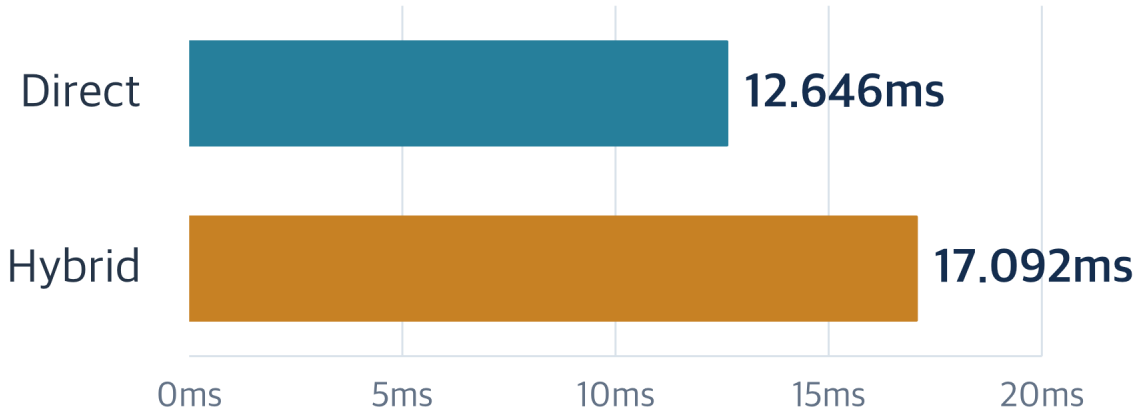
Distributed의 통신 비용을 개선한 뒤에도, ResNet56 단일 서빙의 지연시간을 넘었습니다.

평균 지연시간



통신 최적화 이후에도 평균 지연 증가

p95 지연시간



꼬리 지연시간에서도 Direct가 더 낮음

이번 조건에서는 통신 개선만으로 단일 모델보다 빠른 추론을 달성하지 못함

원인을 Expert 선택 분포와 실제 모델 실행시간으로 분석합니다. →

Direct·Hybrid는 각각 초기 비교·최적화 실험의 결과이며, 할당 자원도 다름. 두 그래프는 동일한 길이 척도 사용.

선택 분포와 실제 실행 비용의 영향

계산 절감이 특징 추출·Dispatcher·남은 통신 비용을 상쇄하지 못한 것으로 해석됩니다.

① 추가 Expert 계산이 항상 필요



ShuffleNet 선택 0%

모든 요청에서 특징 추출·Dispatcher 이후 추가 Expert 실행

전체 요청의 68%는 ResNet56까지 실행

Hybrid에도 원격 Expert 호출 1회가 남아 있음

② FLOPs와 실행시간은 비례하지 않음

모델	MFLOPs	실행시간
ShuffleNet	21.80	1.323ms
MobileNet	55.94	1.464ms
ResNet56	251.50	2.939ms

연산량 11.54배 차이
실행시간은 2.22배 차이

다음 과제: 실제 실행 비용을 반영한 학습과 선택 분포 개선

모델별 실행시간은 별도 직접 호출 실험(내부 검증 포함)으로, 특정 CPU·런타임·저부하 조건에 한정.

실제 비용을 반영한 모델 선택으로

관측된 한계를 학습 목적·Expert 구성·서빙 평가에 반영합니다.

확인한 한계	향후 과제
FLOPs ≠ 실제 실행 비용	측정 실행시간·CPU 사용량을 학습 비용에 반영
ResNet56 선택 비율 68%	데이터셋·Expert 조합·학습 설정 비교
모든 요청에서 추가 Expert 실행	특징 추출 모델에서 종료하는 비율과 정확도 함께 평가
저부하 중심 실험	동일 정확도에서 지연·처리량·자원·자동 확장 검증

조기 종료 비율을 높여도 정확도 저하와 기본 처리 비용이 남으므로, 성능 개선 여부는 후속 실험으로 확인해야 합니다.

동적 모델 선택의 효과는
실제 서비스 전체 비용으로 평가해야 합니다.

정확도와 실행 비용을 함께 고려하는 후속 실험

추가 오프라인 실험의 범위

본문 서빙 실험과 별도로 extractor·후보군의 영향을 분석

구분	본문 서빙 실험	추가 오프라인 분석
목적	실행 구조와 서빙 비용	Extractor·후보군 영향
대상	고정 dispatcher	10개 모델 구성
지표	지연시간·처리량·실행 비용	정확도·평균 MFLOPs

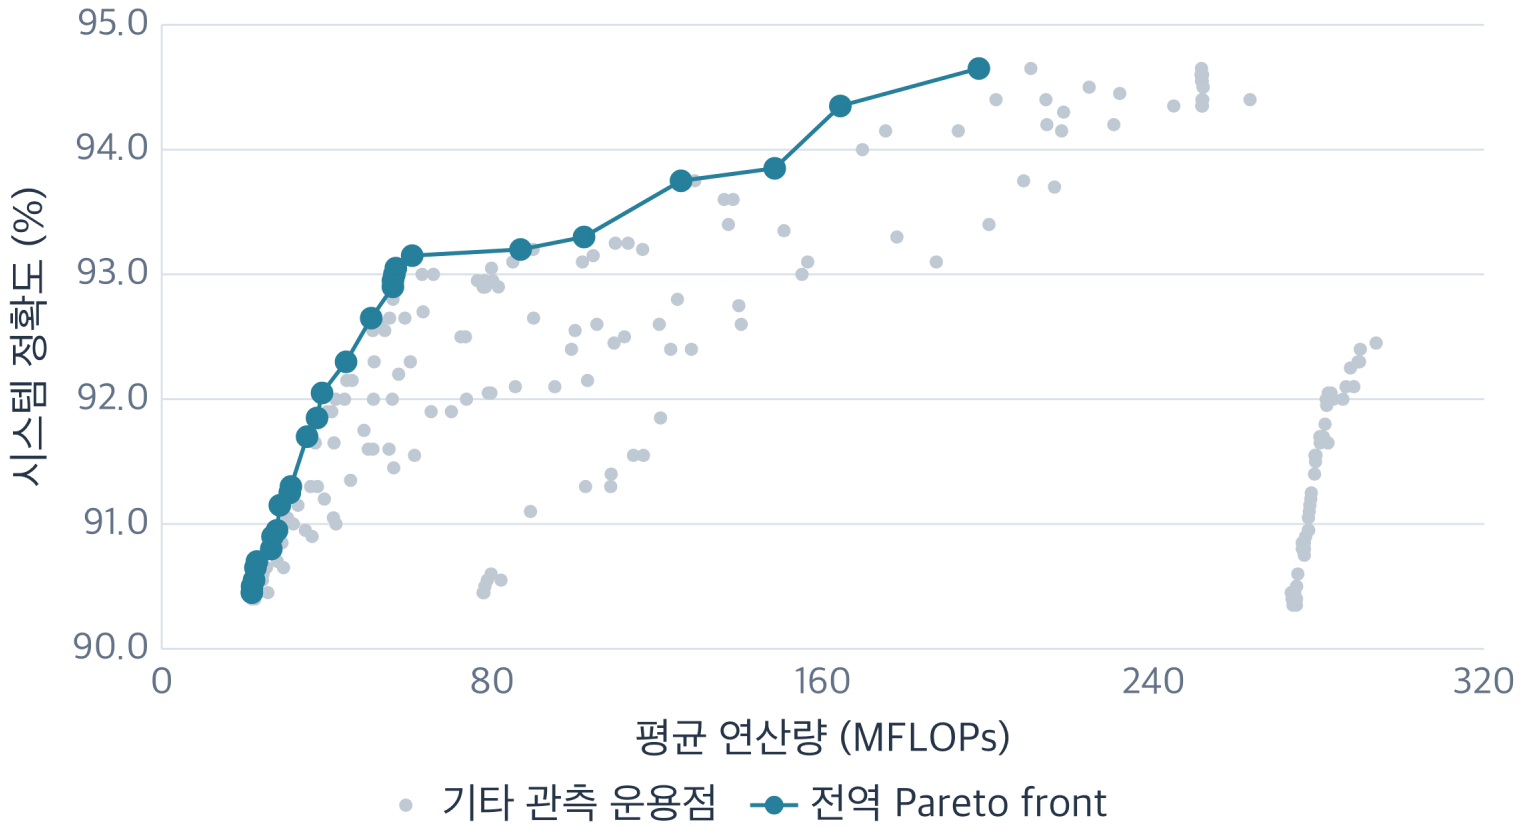
공통 실험 조건

CIFAR-10 test: 학습 6,000 / 탐색 2,000 / 평가 2,000장
Seed 20260824 · 20 epochs · NSGA-II 50 × 50회

본문과 데이터 분할 및 dispatcher가 다른 별도 실험

10개 모델 구성의 통합 Pareto front

최종 평가 운용점을 통합하여 정확도와 평균 연산량 비교



전역 비지배 해

27개 운용점

10개 구성의 결과 통합

최고 정확도 94.65%
197.728 MFLOPs

요구 정확도와 예산에 따라
경계 위 운용점 선택

최종 평가 6,560건의 고유 좌표 257개 · 관측 결과 내 전역 Pareto front

요구 조건별 운용점 선택

예산에서는 최고 정확도, 정확도 하한에서는 최소 연산량을 선택

요구 조건	Extractor / 후보군	정확도	평균 MFLOPs
예산 ≤ 50 MFLOPs	S / S+M+R	92.30%	44.602
예산 ≤ 100 MFLOPs	S / M+R	93.20%	86.838
정확도 ≥ 93.0%	M / S+M+R	93.00%	56.302
정확도 ≥ 94.0%	M / S+M+R	94.35%	164.212
정확도 ≥ 94.5%	**S / S+R**	**94.65%**	**197.728**
정확도 ≥ 94.5% 예산 ≤ 175 MFLOPs	관측 해 없음	—	—

관측된 운용점의 오프라인 선택 결과

자동 서비스 전환 또는 실제 지연시간 충족을 의미하지 않음

조합별 상세 결과와 해석 범위

10개 구성의 관측 결과 · 비용 단위는 MFLOPs

추출 모델	후보군	관측 비용 범위	최고 정확도	해당 비용
S	S+M+R	21.806-192.743	94.15%	192.743
M	S+M+R	55.948-164.212	94.35%	164.212
R	S+M+R	251.500	94.60%	251.500
S	S+M	21.804-55.144	92.65%	55.144
M	S+M	55.945-55.956	92.95%	55.956
R	S+M	273.300-293.853	92.45%	293.853
S	**S+R**	**21.804-197.728**	**94.65%**	**197.728**
M	S+R	77.745-263.343	94.40%	263.343
R	S+R	251.500-251.598	94.65%	251.598
S	M+R	77.744-224.414	94.50%	224.414

단일 seed의 관측 결과 · 선택 후 독립 평가 및 목표 장치의 서빙 검증 필요